

Resumen ejecutivo proyecto

PREDICTOR DE FIBROSIS POR ECOGRAFÍA (PFE)

19-10-2025

Cristian René Méndez Gacharná
Mateo Parra Ochoa
Carlos Andrés García Gómez

1. Definición de la Problemática

La Enfermedad Hepática Grasa Asociada a Disfunción Metabólica (MASH) se ha consolidado como la principal causa de enfermedad hepática crónica a nivel mundial, con una prevalencia que aumenta de forma paralela a las epidemias de obesidad y diabetes tipo 2. El principal desafío clínico radica en la progresión silenciosa de la esteatosis hacia la fibrosis hepática significativa (estadios F $\geq$ 2), la cual marca el punto de inflexión para el desarrollo de complicaciones severas, como la cirrosis descompensada, el fallo hepático y el carcinoma hepatocelular.

Los métodos diagnósticos actuales presentan limitaciones operativas y de acceso poblacional. La biopsia hepática, aunque es el estándar para detección de la enfermedad, es invasiva, costosa, propensa a errores de muestreo e inviable para el monitoreo de rutina. Los métodos no invasivos basados en rigidez (elastografía), si bien son precisos, requieren equipos especializados de alto costo y personal entrenado, lo cual restringe el uso a centros no especializados. Finalmente, los scores séricos (FIB-4, APRI) son útiles para descartar fibrosis, pero su baja especificidad a menudo genera una zona gris de resultados indeterminados, lo que conduce a la sobrecarga de los sistemas de imagen especializados. En consecuencia, existe una brecha crítica en la capacidad del sistema de salud para identificar de manera temprana y masiva a los pacientes que requieren intervención, lo que retrasa el tratamiento y eleva la morbi-mortalidad.

Conceptos Clave

- **Fibrosis Hepática:** Se caracteriza por la acumulación de tejido fibroso o cicatrizal en el parénquima hepático (el órgano). Es una secuela de daño crónico o grave en el hígado. Sus etapas van desde leve hasta severa, culminando en cirrosis hepática (F4).
- **EHNA/MASH:** Una condición heterogénea que incluye hígado graso y esteatohepatitis hepática no alcohólica. Se caracteriza por la acumulación de grasa en el hígado y está relacionada con patologías como obesidad, diabetes mellitus y dislipidemias. Su cronicidad provoca inflamación permanente que lleva a la fibrosis.

- **Impacto de la Enfermedad:** Es una enfermedad con distribución mundial, que afecta especialmente a adultos con las condiciones mencionadas. Contribuye a una alta morbilidad y mortalidad, siendo una causa importante de trasplante hepático. Las complicaciones severas incluyen ascitis, hemorragias y encefalopatías. Clasifique correctamente el estadio de fibrosis hepática de un paciente con base en parámetros clínicos (APRI y FIB-4) y en una ecografía como imagen de diagnóstico, que ofrece menos información, pero cuya obtención es más práctica.
- **Estadíos escala METAVIR:** F0 (normal), F1 (fibrosis portal), F2 (fibrosis periportal), F3 (fibrosis septal) y F4 (cirrosis) .

1.1. Entendimiento del Negocio

El valor del proyecto radica en ofrecer una solución automatizada de bajo costo y alta disponibilidad que optimice el flujo de trabajo diagnóstico y reduzca la carga económica para la detección y clasificación de los estadios de la enfermedad hepática crónica con base en parámetros clínicos (APRI y FIB-4) e imágenes de ecografía en modo B (la herramienta de imagen más accesible y económica globalmente). El modelo transforma un examen convencional en una prueba de diagnóstico predictivo a través de herramientas de machine learning.

Llevar a cabo esta solución supone los siguientes impactos:

1. **Optimización del Triage Clínico:** El modelo permite identificar a los pacientes en el momento crítico de la enfermedad ($F \geq 2$), permitiendo al personal de atención primaria realizar un triage efectivo. Los pacientes clasificados con alto riesgo pueden ser derivados a intervenciones terapéuticas o a pruebas confirmatorias costosas (elastografía) solo cuando la probabilidad de fibrosis avanzada es alta.
2. **Reducción de Costos:** Al aprovechar la infraestructura de ultrasonido existente, se elimina la necesidad de inversión en nuevos equipos de elastografía. Esto democratiza el diagnóstico y disminuye el costo unitario por paciente evaluado.
3. **Impacto en Salud Pública:** Al facilitar la detección temprana en entornos comunitarios o de atención primaria, el modelo aumenta la ventana de oportunidad para la reversión o ralentización de la enfermedad, lo que tiene el potencial de reducir drásticamente las tasas de cirrosis, trasplante hepático y mortalidad asociada en la población general.

2. Ideación

Potenciales Usuarios:

El Sistema de Diagnóstico Asistido por Computadora está diseñado para beneficiar a los siguientes usuarios:

Usuario	Proceso Actual	Dolor Relacionado
Médico de Atención Primaria (MAP)	Realiza el screening inicial con factores de riesgo y scores séricos (FIB-4, APRI).	Ambigüedad y Sobre-derivación: Los scores séricos son a menudo inespecíficos (zona gris), lo que obliga a derivar innecesariamente a especialistas y sobrecarga el sistema.
Hepatólogo/Especialista	Evalúa pacientes de alto riesgo y programa pruebas especializadas (elastografía o biopsia).	Sobrecarga de Casos Innecesarios: Recibe una gran cantidad de referencias con resultados de scores indeterminados, lo que consume tiempo valioso y genera largas listas de espera para pruebas confirmatorias.
Radiólogo / Técnico de Ultrasonido	Realiza ecografías en modo B; la interpretación de la fibrosis temprana (F0 a F2) es subjetiva.	Subjetividad y baja sensibilidad: El ultrasonido convencional es ciego para los estadios tempranos de fibrosis. No puede emitir un diagnóstico de staging con la precisión requerida.
Administrador/Gerente de Salud	Gestiona los recursos (presupuesto, tiempo de equipos especializados).	Alto Costo Operacional: Gasto elevado en pruebas confirmatorias costosas (elastografía) para casos que podrían ser de bajo riesgo. Costos crecientes por morbilidad debido a diagnósticos tardíos.

Mockup

Predictor de Fibrosis por Ecografía (PFE)

ROI Analizada por IA

Imagen de Ecografía Hepática (Modo B)

2. INPUTS CLÍNICOS

AST: 45 UI/L
Plaquetas: 180 (x10⁹/L)
Edad/IMC: 55 años / 32

3. CLASIFICACIÓN PFE (SALIDA IA)

RIESGO ALTO (F≥2)

****Puntuación de Probabilidad:** 89%** de Fibrosis Sig.**

4. DETALLE ANALÍTICO (Interpretabilidad)

FIB-4 Calculado: 2.5 (Alto Riesgo)

****Factores de Influencia (IA):****

- Textura Hepática (Radiónica): 60%
- Scores Clínicos (FIB-4/APRI): 30%

5. RECOMENDACIÓN CLÍNICA (Triage Automatizado)

****ACCIÓN SUGERIDA:**** Derivación inmediata a Elastografía/Hepatología para confirmación.
Iniciar plan de control metabólico y seguimiento intensivo.

Hipótesis que guiaran el proceso de desarrollo del producto

Inicialmente se establecieron las siguientes hipótesis con respecto a los datos que fueron recolectados:

- La edad del paciente influye en el estadio de la fibrosis que se le es diagnosticada
- La fibrosis hepática se presenta con mayor frecuencia en pacientes del sexo femenino

Pregunta de Investigación

¿Puede un modelo de inteligencia artificial identificar de manera temprana y precisa la fibrosis hepática significativa ($F \geq 2$) utilizando únicamente datos clínicos y ecografías convencionales?

a. Fuente y Descripción de Datos

El modelo recibirá como fuentes de datos, por un lado, un conjunto de imágenes de ecografía etiquetadas según el estadio de fibrosis diagnosticado, y por el otro, una serie de parámetros clínicos obtenidos en laboratorio, ambos provistos por el hospital Fundación Santafé de Bogotá. Las imágenes tienen el formato Tipo B, esto es, una imagen bidimensional con un único canal de escala de grises, y cuyas dimensiones son 800x600 (aún por verificar). Con respecto a los parámetros clínicos, éstos se describen a continuación con sus unidades de medidas y rangos normales:

- Recuento de Plaquetas: $150-400 \times 10^9/L$
- Aspartato Aminotransferasa (AST): 8-40 UI/L
- Alanina Aminotransferasa (ALT): 4-36 UI/L
- Edad: 0-90 años
- Gamma Glutamyltransferasa (GGT): 5-40 UI/L
- Deshidrogenasa Láctica (DHL): 100-360 UI/L
- Fosfatasa Alcalina: 40-150 UI/L
- Tiempo de Protrombina (PT): 0.8-1.2 INR
- Bilirrubina Total: 0.1-1.2 mg/dL
- Bilirrubina Directa: 0.1-0.4 mg/dL
- Nivel de fibrosis: valor de F0 a F4, esta es la **variable de salida**

A partir de los dos primeros valores, se puede calcular el indicador APRI; a partir de los cuatro primeros, el indicador FIB-4, y de la diferencia de los dos últimos, la bilirrubina indirecta. Además, todos los parámetros clínicos, con excepción de la edad y el nivel de fibrosis, han sido medidos varias veces para cada paciente, por lo que el valor final de cada parámetro asignado a cada uno corresponderá al promedio de todas las mediciones.

3. Responsable

El proyecto implicó el uso de datos sensibles en salud (exámenes de laboratorio e imágenes médicas). Para proteger la privacidad y confidencialidad de los pacientes, todos los datos fueron anonimizados antes de su procesamiento, eliminando identificadores directos y reduciendo el riesgo de reidentificación. Estas medidas cumplen con la Ley 1581 de 2012, el Decreto 1377 de 2013 y los lineamientos éticos de la Resolución 8430 de 1993, que regulan el tratamiento de datos personales y la investigación con seres humanos en Colombia.

En términos de transparencia y responsabilidad, se documentó todo el proceso analítico (preprocesamiento, entrenamiento y validación de modelos) y se evaluaron riesgos relacionados con sesgos, interpretabilidad y uso clínico. Se enfatiza que el modelo debe utilizarse como herramienta de apoyo y no como sustituto de decisiones profesionales, y que cualquier implementación requerirá monitoreo continuo y validación adicional.

4. Análisis y Exploración de datos

Para la exploración de datos se adjuntan dos notebooks con el proceso de ingeniería de datos correspondiente asegurando su calidad e integridad, por lo que se insta al equipo docente a dirigirse a los notebooks para visualizar el contenido. En este documento se mencionan los insights principales abstraídos del análisis.

5. Insights principales del análisis

1. Distribución de la fibrosis:
Los estadios más frecuentes son F1 (35%) y F3–F4 (~25% cada uno), lo que indica que la mayoría de los pacientes presentan fibrosis leve o avanzada, con menor representación de casos intermedios (F2) y normales (F0).
2. Diagnósticos asociados:
Los diagnósticos más comunes en los estadios F0–F2 son *degeneración grasa del hígado*, mientras que en F3–F4 predominan *otras cirrosis del hígado*, reflejando una progresión clínica coherente con el avance de la enfermedad.
3. Fibrosis como diagnóstico principal:
F1 es el estadio más frecuente cuando la fibrosis aparece como diagnóstico principal (~36%), lo que sugiere que muchos pacientes son detectados en fases tempranas o bajo seguimiento preventivo.
4. Eventos clínicos y progresión:
Los pacientes en estadios F1, F3 y F4 concentran el mayor número de eventos clínicos, evidenciando que los casos con fibrosis leve o avanzada requieren más seguimiento o presentan mayor actividad médica.
5. Edad promedio y gravedad:
La edad promedio varía poco entre estadios (60–66 años), indicando que la progresión de la fibrosis no está fuertemente determinada por la edad sino por otros factores metabólicos o clínicos.

6. Sexo y prevalencia:
Las mujeres presentan una mayor frecuencia de fibrosis en casi todos los estadios, especialmente en F1 y F3, lo que podría deberse a una mayor detección o seguimiento en población femenina.
7. Diagnósticos múltiples:
Más del 40% de los pacientes tienen más de un diagnóstico registrado, siendo la degeneración grasa del hígado y la fibrosis hepática las condiciones que más coexisten, lo cual sugiere una relación estrecha entre hígado graso y desarrollo de fibrosis.
8. Edad y diagnóstico:
Los diagnósticos asociados a fibrosis avanzada y cirrosis aparecen en pacientes con edades promedio más altas (~65–70 años), mientras que aquellos relacionados con esteatosis y obesidad se concentran en pacientes más jóvenes.
9. Pacientes con mayor número de eventos:
Los tres pacientes con más eventos clínicos presentan fibrosis en estadios F1 y F3, lo que refuerza la idea de que estos niveles intermedios son los más monitoreados y con mayor carga de seguimiento hospitalario.
10. Implicación clínica general:
La evolución de los diagnósticos y la concentración de eventos sugieren que la detección temprana y el control de factores metabólicos son claves para evitar la progresión hacia fibrosis avanzada o cirrosis (F4).

6. Construcción y evaluación del modelo

Para la construcción del producto de datos se usaron 2 modelos, uno para la detección de fibrosis en imágenes médicas y otro modelo haciendo uso de datos de exámenes de laboratorios.

Para el modelo alimentado por laboratorios se entrenaron varios modelos usando 3 algoritmos con diferentes hiperparámetros, obteniendo que el modelo de Random forest obtuvo mejores métricas en general, logrando clasificar correctamente el estadio de fibrosis en el 95% de los casos.

Para el modelo de análisis de imágenes se tiene que predice el estadio correctamente el 90% de las veces.

6. Construcción del Producto de Datos

El *Predictor de Fibrosis por Ecografía (PFE)* fue implementado como un producto de datos integral, combinando modelos de machine learning, una API operativa y una interfaz web funcional. El sistema unifica preprocesamiento, inferencia e interpretabilidad dentro de una plataforma accesible para el personal clínico.

6.1 Componentes del Producto

Modelo clínico (Random Forest).

Para los datos de laboratorio se seleccionó un Random Forest entrenado con APRI, FIB-4 y el panel hepático completo, alcanzando una precisión del 94.98% y alta sensibilidad para detectar fibrosis significativa ($F \geq 2$). Su salida consiste en una clasificación binaria y una probabilidad asociada.

Modelo de imágenes (TextureDenseNet).

Para ecografías modo B se desarrolló una arquitectura basada en DenseNet con mecanismos de realce de textura, obteniendo 89.11% de precisión en la clasificación F0–F4. El modelo incorpora Grad-CAM para asegurar interpretabilidad clínica.

6.2 API REST

Se implementó una API en FastAPI que estandariza el acceso a los modelos y centraliza la inferencia. Ofrece tres rutas principales para predicción con datos clínicos, imágenes o ambos de manera combinada. La API permite escalabilidad y modularidad, funcionando como núcleo lógico del sistema.

6.3 Interfaz Web (Streamlit)

Se construyó una aplicación web disponible en:

<https://liver-fibrosis-detection-through-images.streamlit.app>

La herramienta permite:

- Cargar una ecografía y obtener estadio predicho, probabilidad y Grad-CAM.
- Ingresar valores clínicos y obtener la predicción de riesgo $F \geq 2$.

La interfaz fue diseñada para médicos generales, radiólogos y personal clínico que requiere una herramienta intuitiva sin conocimientos técnicos de machine learning.

6.4 Despliegue

El sistema fue desplegado en Streamlit Cloud mediante un contenedor que integra API y modelos. Esto habilita reproducibilidad, acceso multiplataforma, actualizaciones rápidas y ejecución segura de la inferencia.

7. Retroalimentación por parte de la organización

Se van a mencionar las 3 interacciones principales que se tuvieron con los stakeholders. En este caso se tuvo una reunión inicial el 16 de Septiembre en donde se presentó el proyecto al equipo y se delimitaron de manera general los alcances que se buscaban con el desarrollo del proyecto, junto con los tipos de

datos que serían suministrados. Hubo una segunda interacción el 17 de Septiembre en donde se hizo el intercambio de los acuerdos de confidencialidad por parte de nuestro equipo y se nos hizo entrega de los datos de laboratorios (las imágenes clínicas nos fueron entregadas más tarde).

Finalmente nos reunimos con los stakeholders el 30 de Octubre para resolver algunas dudas respecto a los datos que nos fueron suministrados al igual que del producto de datos esperado.

8. Conclusiones

Conclusión 1 — Cumplimiento de objetivos y aporte del producto de datos

El proyecto cumplió completamente sus objetivos: se desarrolló un sistema capaz de identificar fibrosis significativa ($F \geq 2$) mediante datos clínicos e imágenes ecográficas modo B, logrando desempeños competitivos (95% en modelo clínico y 89% en modelo de imágenes). El producto final —que incluye API, modelo desplegado e interfaz web funcional— demuestra que la solución es viable y aplicable al flujo de atención real, especialmente para el triage temprano en atención primaria.

Conclusión 2 — Principales dificultades técnicas y de datos enfrentadas

Durante el desarrollo surgieron desafíos importantes: el desbalance de clases (especialmente F0 y F2), la variabilidad entre equipos ecográficos, la necesidad de un preprocesamiento riguroso (ruido speckle, artefactos, textos y bordes), y la limitación de datos provenientes de un único centro. Estas dificultades se mitigaron mediante algoritmos específicos de limpieza, uso de class weights y ajustes cuidadosos del entrenamiento, evidenciando la madurez técnica del modelo.

Conclusión 3 — Impacto esperado en KPIs clínicos y operativos

Su despliegue en un entorno real podría generar mejoras significativas: reducción estimada de 35–50% en derivaciones innecesarias a elastografía, aumento del 20–30% en la detección temprana de $F \geq 2$, y reducción de 15–25% en los tiempos de espera para evaluación especializada. Esto se traduce en un uso más eficiente de recursos, mayor precisión en triage y un impacto directo en la calidad de atención y en los costos institucionales.

Conclusión 4 — Suficiencia del modelo y condiciones para mejorar su generalización

El modelo es suficientemente robusto para cumplir su propósito central como herramienta de apoyo en triage clínico, pero su desempeño podría optimizarse con datos más diversos: mayor número de imágenes, distribución balanceada de clases, bases multi-centro, incorporación de metadatos técnicos del ecógrafo y datos longitudinales. Aunque la solución no reemplaza el diagnóstico definitivo, es adecuada para orientar decisiones tempranas y tiene potencial para escalar a sistemas clínicos reales con validación adicional.